

BitVLA-TAR 实验报告

日期: 2026-04-01

汇报人: 何宁秋

模型基座: BitVLA (bitvla-bf16)

任务集: LIBERO-10 (libero_10_no_noops)

一、研究背景与目的

问题发现

研究起点是对已有的 BitVLA 模型 `ft-bitvla-libero-long` 进行完整评测。该模型由 `bitvla-bf16` (base 模型) 在 LIBERO-10 数据集上经过全参数微调 **10001 步 (4 卡, effective batch=64)** 训练得到, 是本研究的 baseline 模型。

Baseline Eval 配置:

参数	值
模型	<code>ft-bitvla-libero-long</code>
任务集	LIBERO-10 (10 个任务)
每任务 trials	50 次
总 episodes	500
eval 耗时	~14 小时

备注:

eval 运行, 使用脚本:

```
/root/autodl-tmp/robotic/src/BitVLA/opencvla-oft/experiments/robot/libero/run_libero_eval_bitnet.py
```

eval 过程同步记录每个 episode 的逐步动作序列并计算平滑度指标, 结果保存至:

```
/root/autodl-tmp/robotic/src/BitVLA/opencvla-oft/experiments/logs/full_eval_long/smoothness.json
```

背景说明:

BitVLA 采用 **chunk-based 动作预测**: 模型每次不预测单步动作, 而是一次性预测未来 8 步的动作序列 (称为一个 **chunk**), 机器人按序执行后再请求下一个 chunk。这种方式提高了推理效率, 但带来一个潜在问题: 相邻两个 chunk 的衔接处, 动作值可能出现突然跳变。

Baseline Eval 结果:

指标	数值	说明
成功率	86.4%	500 次任务测试中 432 次成功完成

指标	数值	说明
s1 (chunk 内平均抖动)	0.0154	单个 chunk 内部相邻两步之间的平均动作变化量
inter_boundary_jump (chunk 边界跳变)	0.0477	上一个 chunk 最后一步 → 下一个 chunk 第一步的平均动作跳变量

指标解读：

- s1 = 0.0154：chunk **内部**每步动作变化约 0.015，动作连续、平滑
- inter_boundary_jump = 0.0477：两个 chunk **衔接处**的动作跳变约 0.048，是内部抖动的 **3 倍**

换句话说，机器人在执行完一段动作、切换到下一段动作时，动作幅度会突然"抖一下"，这个抖动明显大于正常动作过程中的自然变化。这在物理机器人上可能表现为关节的突然抖动或轨迹不连贯，影响操作稳定性。

关键发现：动作不平滑的根源不在于模型预测单个 chunk 的质量（内部平滑），而在于**模型对相邻 chunk 之间衔接的一致性缺乏约束**。这正是 TAR 的设计切入点。

研究目标

提出 **TAR (Temporal Action Regularization)**，通过在训练时对 chunk 首尾动作速度施加惩罚，降低 inter_boundary_jump，同时维持任务成功率。

二、方法设计

TAR Loss 公式

公式 1：总损失函数

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{L1}} + \lambda_{\text{TAR}} \cdot \mathcal{L}_{\text{TAR}}$$

解释：

总损失 = 原有的 L1 动作预测损失 + TAR 正则项（由超参数 λ 控制权重）。 $\lambda=0$ 时退化为原始训练。

公式 2：TAR 正则项

$$\mathcal{L}_{\text{TAR}} = \frac{1}{B \cdot D} \sum_{b,d} (|a_{b,1,d} - a_{b,0,d}| + |a_{b,T-1,d} - a_{b,T-2,d}|)$$

符号说明：

符号	含义
B	batch size (批次大小)
D	动作维度 (如 7 自由度关节角)
T	chunk 长度 (模型一次预测的动作步数)
a_{b,t,d}	第 b 个样本、chunk 内第 t 步、第 d 维的动作值

解释：


TAR 惩罚的是 **chunk 首尾的瞬时速度**：

- 第一项：chunk **起始两步**（步 0→1）的动作变化
- 第二项：chunk **末尾两步**（步 T-2→T-1）的动作变化

除以 $B \cdot D$ 做归一化，使损失值与 batch 大小和动作维度无关。

直观理解

text



- 不加 TAR：chunk 内部平滑，但 chunk 衔接处可能“跳变”（边界跳变 = 0.0477）
- 加 TAR：训练时强制约束首尾速度，降低衔接跳变（预期 < 0.03）

其他说明：

- 第一项惩罚 chunk **起始速度**（步 0→1）
- 第二项惩罚 chunk **末尾速度**（步 T-2→T-1）
- `tar_lambda=0.0` 时等价于原始训练，**零额外开销**

代码实现

修改文件：`openvla-oft/vla-scripts/finetune_bitnet.py`，新增 `tar_lambda` 超参数，在 `run_forward_pass()` 中计算并叠加 TAR loss，训练日志中同步追踪 `tar_loss`。

实验对照设计

组别	tar_lambda	意义
noTAR (对照组)	0.0	无正则，基准线
TAR (实验组)	0.05	TAR 正则化

三、实验过程

阶段 0：Baseline 测量

目标：建立性能基准，量化平滑度问题。

配置：使用 `ft-bitvla-libero-long` (bitvla-bf16 全参数微调 10001 步，4 卡，86.4%)，在 LIBERO-10 上运行完整 eval (500 episodes, 50 trials/task)。

结果：

指标	数值
成功率	86.4%
<code>inter_boundary_jump</code>	0.0477
<code>s1</code>	0.0154

意义：确认边界跳变是主要平滑度问题，为 TAR 提供量化改进目标。

阶段 1：v1 方案（失败）

目标：在 base 模型上加 LoRA 微调，验证 TAR 机制。

配置：

参数	值
起点模型	<code>bitvla-bf16</code> (未经 LIBERO 训练)
训练方式	LoRA (rank 32)
训练步数	1,000 步
GPU	1 卡

结果：notar-v1 成功率 **1.5%** (500 episodes 中 5 次成功)，eval 终止，tar-v1 未执行。

失败根源：从 base 模型出发，1000 步 LoRA 远不足以学会任务 (baseline 需要 4 卡全参数微调 10001 步，v1 训练量不足 baseline 的 2%)。

教训：在 noTAR 组已失败的情况下，TAR 组同样无意义，及时终止是正确决策。

阶段 2：v2 方案（部分失败，有副发现）

目标：修正 v1 起点问题，从已收敛的 86.4% 模型出发，做 LoRA fine-tuning 对比实验。

核心假设：从已收敛的专用模型出发，少量 LoRA 步骤即可维持任务能力，同时验证 TAR 改善平滑度。

配置：

参数	v1	v2
起点模型	bitvla-bf16	ft-bitvla-libero-long (86.4%)
训练方式	LoRA rank 32	LoRA rank 32
学习率	4e-4	2e-4
训练步数	1,000 步	1,000 步
GPU	1 卡	1 卡

训练过程：

模型	时间	耗时	最终 l1_loss	tar_loss
notar-v2	03-31 15:22 → 19:54	4h 32min	0.080	—
tar-v2	03-31 19:54 → 04-01 00:22	4h 28min	0.069	0.0019

Mini Eval 结果 (5 trials/task, 50 episodes, 2026-04-01)：

指标	Baseline	notar-v2	tar-v2	v2 预期
成功率	86.4%	22.0% ❌	48.0% ❌	~80-90%
inter_boundary_jump	0.0477	0.0614 ❌	0.0546	< 0.03
s1	0.0154	0.0107	0.0109	≈ baseline

失败根因：

在已收敛的全参数专用模型上叠加 LoRA 微调，导致灾难性干扰：

- LoRA adapter 随机初始化为已收敛权重引入噪声
- lr=2e-4 + 1000步足以破坏原有权重平衡，但不足以重建任务能力
- notar-v2 的 InterBoundary (0.0614) 甚至比 baseline (0.0477) 更差

关键副发现（有学术价值）：

tar-v2 (48%) 显著优于 notar-v2 (22%)，差距远超统计误差：

TAR 正则化不仅改善动作平滑度，还在 LoRA 微调场景中抑制了权重的过激更新，起到维持模型泛化能力的正则化作用。

v2 假设	实际结论
notar-v2 ≈ baseline 成功率	❌ 实际 22%
TAR 可能略微降低成功率	✅ TAR 反而提升成功率 (22%→48%)
TAR 降低 InterBoundary	✅ 方向正确 (0.0614→0.0546)

阶段 3：v3 方案（待执行）

目标：消除 v1/v2 的方法论缺陷，复刻原始训练流程，唯一变量为 TAR。

设计原则：baseline 是全参数微调 10001 步 4 卡，v3-TAR 必须采用完全相同的配置，才能做干净的对照实验。

配置：

参数	baseline（已有）	v3-TAR（待训练）
起点模型	bitv1a-bf16	bitv1a-bf16
训练方式	全参数微调	全参数微调
GPU	4 卡	4 卡
max_steps	10,001	10,001
effective batch	64	64
learning_rate	4e-4	4e-4
image_aug	True	True
tar_lambda	0.0	0.05

预期结果：

指标	Baseline	v3-TAR（预期）
成功率	86.4%	~84-88%（影响微小）
inter_boundary_jump	0.0477	< 0.03（目标，降低 40%+）
s1	0.0154	接近或略高于 baseline

时间估算：训练 ~11h（4 卡） + Eval ~14h（1 卡） = 总计 ~25h

四、结果汇总

方案	成功率	InterBoundary	结论
Baseline	86.4%	0.0477	参考基准
v1-notar	1.5%	—	✗ 训练量严重不足
v2-notar	22.0%	0.0614	✗ LoRA 干扰导致性能崩溃
v2-tar	48.0%	0.0546	✗ 绝对值低，但 TAR 正则化效果显著
v3-tar	~86%（预期）	< 0.03（预期）	待执行

五、结论

1. **TAR 机制有效**: 在 v2 对照中, TAR 将成功率从 22% 提升至 48%, InterBoundary 从 0.0614 降至 0.0546, 方向完全正确。
 2. **方法论要求严格**: LoRA 在已收敛专用模型上微调会产生强干扰, 无法做干净的实验对比; 必须与 baseline 采用完全一致的训练配置。
 3. **v3 是正确方案**: 全参数微调 + TAR, 复刻原始训练, 预期在维持 ~86% 成功率的同时将 InterBoundary 降低 40%+ 至 < 0.03 。
 4. **TAR 的额外价值**: v2 的副发现表明 TAR 在 LoRA 场景下兼具正则化效果, 这是一个值得在论文中独立讨论的发现。
-

六、下一步行动

- ☐ 切换至 4 卡 AutoDL 实例, 数据盘数据 (bitvla-bf16、modified_libero_rlds) 自动保留
- ☐ 运行 `ft_bitvla_libero_v3_tar.sh` (~11h)
- ☐ 切回单卡实例运行 eval (~14h)
- ☐ 对比 v3-TAR vs baseline, 输出最终论文数据