

BitVLA-TAR v4 消融实验报告

日期：2026-05-04

汇报人：何宁秋

模型基座：BitVLA (bitvla-bf16)

任务集：LIBERO-10 (libero_10_no_noops)

实验目的：对 TAR 正则化强度 tar_lambda 进行消融实验，测试 $\lambda=0.01$ 和 $\lambda=0.1$ 两个值，结合已有的 $\lambda=0.0$ (baseline) 和 $\lambda=0.05$ (v3)，构建完整的 4 点消融曲线，验证 TAR 强度与任务成功率、动作平滑度之间的关系。

一、实验背景

已有实验数据

方案	tar_lambda	成功率	InterBoundary	S1	MaxJump
Baseline	0.00	86.4%	0.0477	0.0154	0.1613
v3-TAR	0.05	90.8%	0.0451	0.0104	0.0794

v3 实验（详见 20260418-实验.md）证明 tar_lambda=0.05 可将成功率从 86.4% 提升至 90.8% (+4.4%)，同时全面改善动作平滑度。但仅有 2 个数据点无法回答：

- TAR 的效果是否随 λ 单调变化？还是存在最优点后性能下降？
- 更小/更大的 λ 表现如何？论文需要消融曲线支撑超参数选择。

消融设计

选择 $\lambda=0.01$ （弱正则）和 $\lambda=0.1$ （强正则）两个消融点，与已有的 $\lambda=0.0$ 和 $\lambda=0.05$ 组成 4 点消融曲线：

组别	tar_lambda	说明
Baseline	0.00	无 TAR，已有数据
消融 A	0.01	弱正则，新增
v3	0.05	中等正则，已有数据
消融 B	0.10	强正则，新增

二、实验配置

训练配置

消融 A 和 B 的训练配置与 v3 完全一致，唯一变量为 tar_lambda。

参数	消融 A	消融 B	v3（参考）
起点模型	bitvla-bf16	bitvla-bf16	bitvla-bf16
训练方式	全参数微调	全参数微调	全参数微调
GPU	4×4090D (FSDP)	4×4090D (FSDP)	4×4090D (FSDP)
max_steps	10,001	10,001	10,001
effective batch	64 (bs=2 × accum=8 × 4卡)	64	64
learning_rate	4e-4	4e-4	4e-4
lr_vit	8e-5	8e-5	8e-5
image_aug	True	True	True
gradient_checkpointing	True	True	True
tar_lambda	0.01	0.10	0.05

关键文件

文件	说明
<code>ft_script/ft_bitvla_libero_v4_tar001.sh</code>	消融 A 训练脚本
<code>ft_script/ft_bitvla_libero_v4_tar01.sh</code>	消融 B 训练脚本
<code>ft_script/eval_bitvla_v4_tar001.sh</code>	消融 A Eval 脚本
<code>ft_script/eval_bitvla_v4_tar01.sh</code>	消融 B Eval 脚本
<code>ft_script/eval_v4_both.sh</code>	Eval A→B 串联脚本

三、训练过程

消融 A（tar_lambda=0.01）

指标	值
启动时间	2026-04-29 21:00
完成时间	2026-05-01 12:59
训练时间	~40 小时
速度	~14.3 秒/步
显存使用	~15GB/24GB per card
最终 loss	~0.076

Loss 下降轨迹（采样点）：

Step	loss
42	0.3013
698	0.1729
3182	0.1165 ~ 0.1242
8727	0.0757 ~ 0.0866
10000	~0.076

训练收敛平稳，loss 从 0.30 持续下降至 0.076，与 v3 最终 loss（0.0746）接近。

Checkpoint：

```
runs/bitvla-bf16+libero_10_no_noops+b16+lr-0.0004--image_aug+tar-0.01--v4-tar001-  
-10000_chkpt/lora_adapter/
```

消融 B（tar_lambda=0.1）

指标	值
启动时间	2026-05-01 13:39
完成时间	2026-05-03 06:06
训练时间	~40 小时
速度	~14.5 秒/步
显存使用	~15GB/24GB per card
最终 loss	~0.085

Loss 下降轨迹（采样点）：

Step	loss
1389	0.138 ~ 0.182
4705	0.080 ~ 0.103
7295	0.081 ~ 0.095
10000	~0.085

消融 B 的最终 loss（~0.085）高于消融 A（~0.076）和 v3（0.0746），符合预期——更强的 TAR 正则项（λ=0.1）增加了总 loss 中的正则化贡献。

Checkpoint：

```
runs/bitvla-bf16+libero_10_no_noops+b16+lr-0.0004--image_aug+tar-0.1--v4-tar01-  
-10000_chkpt/lora_adapter/
```

训练速度对比

方案	速度（秒/步）	总时间
v3 ($\lambda=0.05$)	~17	~45h
消融 A ($\lambda=0.01$)	~14.3	~40h
消融 B ($\lambda=0.1$)	~14.5	~40h

消融 A/B 比 v3 略快，可能是系统环境差异（不同时段 GPU 实例负载不同），TAR 计算本身开销极小。

四、FSDP Checkpoint 修复

每组训练完成后，均需执行与 v3 相同的 3 步修复（详见 20260418-实验.md 第四节）：

- 1. dataset_statistics.json：从父目录复制到 lora_adapter/，确保含 libero_10_no_noops key
- 2. tokenizer + processor 文件：复制 tokenizer.json、tokenizer_config.json、special_tokens_map.json、preprocessor_config.json、processor_config.json 到 lora_adapter/
- 3. proprio_projector / action_head：创建符号链接指向父目录的 .pt 文件

修复验证

两组 checkpoint 均通过完整验证：

检查项	消融 A	消融 B
pytorch_model.bin	✔ 5.9GB	✔ 5.9GB
dataset_statistics (libero_10_no_noops)	✔	✔
tokenizer vocab	✔ 128264	✔ 128264
proprio_projector 符号链接	✔	✔
action_head 符号链接	✔	✔
文件总数	13	13

五、Eval 过程

Eval 配置

参数	值
硬件	1 × NVIDIA GeForce RTX 4090D (24GB)
任务集	LIBERO-10（10 个任务）
每任务 trials	50 次
总 episodes	500 × 2 组 = 1000
运行方式	串联脚本（A 完成后自动启动 B）

Eval 启动

```
screen -dmS v4eval bash ft_script/eval_v4_both.sh
```

Eval 时间线

事件	时间
Eval A 启动	2026-05-03 07:39
Eval A 完成	2026-05-03 ~21:30
Eval B 自动启动	2026-05-03 ~21:30
Eval B 完成	2026-05-04 ~07:00
总耗时	~23 小时

六、最终结果

成功率消融曲线

tar_lambda	成功率	Δ vs Baseline	成功数/总数
0.00 (Baseline)	86.4%	—	432/500
0.01 (消融 A)	89.0%	+2.6%	445/500
0.05 (v3)	90.8%	+4.4%	454/500
0.10 (消融 B)	93.6%	+7.2%	468/500

成功率随 tar_lambda 单调递增，λ=0.10 达到最高成功率 93.6%。

平滑度指标消融对比

tar_lambda	S1 ↓	S2 ↓	MaxJump ↓	InterBoundary ↓	GripperSwitches ↓
0.00	0.0154	0.0119	0.1613	0.0477	0.572
0.01	0.0111	0.0094	0.0844	0.0421	0.497
0.05	0.0104	0.0095	0.0794	0.0451	0.439
0.10	0.0099	0.0091	0.0761	0.0460	0.435

(↓ 表示越低越好)

补充平滑度指标

tar_lambda	EarlyS1	LateS1	Late-Early	SuccessS1	FailS1
0.00	0.0145	0.0164	+0.0019	0.0152	0.0154
0.01	0.0105	0.0117	+0.0011	0.0112	0.0087
0.05	0.0100	0.0109	+0.0009	0.0105	0.0092
0.10	0.0092	0.0105	+0.0013	0.0099	0.0067

训练 loss 对比

tar_lambda	最终 loss	说明
0.00	—	Baseline 未记录 loss
0.01	~0.076	接近 v3
0.05	0.0746	v3 参考
0.10	~0.085	正则项贡献增大，总 loss 偏高

七、结果分析

1. 成功率分析

成功率随 tar_lambda 呈现清晰的**单调递增**趋势：

86.4% → 89.0% → 90.8% → 93.6%			
λ=0	λ=0.01	λ=0.05	λ=0.10

- **λ=0.01**：仅施加微弱正则，成功率提升 2.6%，效果有限但方向正确
- **λ=0.05**：中等正则，成功率提升 4.4%，性价比较好
- **λ=0.10**：强正则，成功率提升 7.2%，是本次实验中的最优值

在测试的 λ 范围内**未观察到性能拐点**，即更强的正则并未导致欠拟合。这表明 TAR 的正则化效果在 $\lambda \leq 0.10$ 范围内是安全的。

2. 平滑度分析

S1（chunk 内平滑度）：

- 随 λ 增大持续降低：0.0154 $\rightarrow$ 0.0111 $\rightarrow$ 0.0104 $\rightarrow$ 0.0099（总降幅 **36%**）
- λ 从 0 到 0.01 的降幅最大（-28%），之后边际递减
- 说明：即使少量 TAR 约束就能显著改善 chunk 内动作的连续性

MaxJump（极端跳变）：

- 从 0.1613 降至 0.0761（**↓53%**）
- $\lambda=0.01$ 时已大幅下降至 0.0844（**↓48%**），后续提升有限
- 说明：TAR 在消除极端异常跳变方面效果尤为显著

InterBoundary（chunk 边界跳变）：

- $\lambda=0.01$ 时达到最低值 **0.0421**（**↓12%**）
- $\lambda=0.05$ 和 $\lambda=0.10$ 时分别回升至 0.0451 和 0.0460
- 说明：过强的 chunk 内约束可能使模型在 chunk 边界处产生略大的修正跳变。这是一个有趣的发现——InterBoundary 的最优 λ （~0.01）与成功率的最优 λ （ ≥ 0.10 ）不一致

GripperSwitches（夹爪抖动）：

- 随 λ 增大持续降低：0.572 $\rightarrow$ 0.497 $\rightarrow$ 0.439 $\rightarrow$ 0.435（**↓24%**）
- 说明：TAR 约束使夹爪动作更加稳定，减少了无意义的开合抖动

3. 成功率与平滑度的关系

指标	与成功率的相关性	最优 λ
成功率	—	≥ 0.10
S1	负相关 	≥ 0.10
MaxJump	负相关 	≥ 0.10
InterBoundary	非单调 	~0.01
GripperSwitches	负相关 	≥ 0.10

成功率与大部分平滑度指标高度一致：更平滑的动作序列 $\rightarrow$ 更高的成功率。**唯一例外是 InterBoundary**，其最低点在 $\lambda=0.01$ ，而非成功率最高的 $\lambda=0.10$ 。这说明 InterBoundary 不是决定成功率的唯一因素——chunk 内部的平滑度（S1、MaxJump）对任务完成的影响更大。

4. TAR 的作用机制

综合 4 个数据点，TAR 的作用可归纳为两个层面：

- 1. **直接效果——动作平滑化**：TAR 惩罚 chunk 首尾的高速度动作，使相邻 chunk 之间的过渡更加平滑。即使 $\lambda=0.01$ 也能将 S1 降低 28%、MaxJump 降低 48%。
- 2. **间接效果——正则化提升泛化**：TAR 作为额外的训练约束，抑制了模型在训练集上的过拟合。这解释了为什么在 $\lambda \leq 0.10$ 范围内，更强的正则不仅没有降低成功率，反而持续提升。

5. 训练 loss 与 eval 性能的关系

tar_lambda	训练 loss	成功率
0.01	~0.076	89.0%
0.05	0.0746	90.8%
0.10	~0.085	93.6%

$\lambda=0.10$ 的训练 loss 最高 (~0.085)，但 eval 成功率也最高 (93.6%)。这进一步印证了 TAR 的正则化效果——较高的训练 loss 反映了更强的约束，而非更差的学习，模型在 eval 时反而泛化得更好。

八、结论

- 1. **TAR 正则化强度与成功率正相关**：在 $\lambda \in [0, 0.10]$ 范围内，成功率随 tar_lambda 单调递增 (86.4% $\rightarrow$ 89.0% $\rightarrow$ 90.8% $\rightarrow$ 93.6%)，未出现过拟合拐点。
- 2. **$\lambda=0.10$ 为当前最优值**：成功率 93.6%，较 baseline 提升 **7.2 个百分点**，较 v3 ($\lambda=0.05$) 提升 **2.8 个百分点**。
- 3. **平滑度指标全面改善**：
 - S1 下降 36% (0.0154 $\rightarrow$ 0.0099)
 - MaxJump 下降 53% (0.1613 $\rightarrow$ 0.0761)
 - GripperSwitches 下降 24% (0.572 $\rightarrow$ 0.435)
- 4. **InterBoundary 存在非单调行为**： $\lambda=0.01$ 时最低 (0.0421)， λ 增大后略回升，说明 chunk 内约束与 chunk 边界跳变之间存在 trade-off。
- 5. **TAR 兼具平滑化和正则化双重效果**：平滑化改善动作质量，正则化抑制过拟合提升泛化，两者共同驱动成功率提升。
- 6. **论文推荐**： $\lambda \in [0.05, 0.10]$ 作为默认超参数区间。 $\lambda=0.05$ 是保守稳健的选择， $\lambda=0.10$ 在当前实验中表现最优。

九、后续方向

- **更大 λ 值探索**：当前消融在 $\lambda=0.10$ 处仍未达到拐点，可测试 $\lambda=0.2、0.5$ 寻找性能饱和点或下降拐点
- **Per-task 分析**：对比 4 个 λ 值在每个任务上的成功率变化，识别哪些任务对 TAR 最敏感
- **更多 benchmark 验证**：在 LIBERO-Spatial、LIBERO-Object 等任务集上验证消融趋势的一致性
- **物理机器人部署**：将 $\lambda=0.10$ 模型部署到真实硬件，验证平滑度改善的实际效果

附录：完整消融数据汇总

成功率

tar_lambda	成功率	Δ	成功数/总数
0.00	86.4%	—	432/500
0.01	89.0%	+2.6%	445/500
0.05	90.8%	+4.4%	454/500
0.10	93.6%	+7.2%	468/500

完整平滑度指标

tar_lambda	S1	S2	MaxJump	InterBoundary	GripperSw	EarlyS1	LateS1	SuccessS1	FailS1
0.00	0.0154	0.0119	0.1613	0.0477	0.572	0.0145	0.0164	0.0152	0.0154
0.01	0.0111	0.0094	0.0844	0.0421	0.497	0.0105	0.0117	0.0112	0.0087
0.05	0.0104	0.0095	0.0794	0.0451	0.439	0.0100	0.0109	0.0105	0.0092
0.10	0.0099	0.0091	0.0761	0.0460	0.435	0.0092	0.0105	0.0099	0.0067

实验时间线

日期	事件
4/29 21:00	消融 A ($\lambda=0.01$) 训练启动
5/01 12:59	消融 A 训练完成, checkpoint 修复
5/01 13:39	消融 B ($\lambda=0.1$) 训练启动
5/03 06:06	消融 B 训练完成, checkpoint 修复
5/03 07:39	Eval A + B 串联启动 (单卡)
5/04 ~07:00	全部 Eval 完成
总耗时	~5 天 (训练 ~80h + eval ~23h)